

Data Cleaning Project

Data Cleaning & Quality Assessment Report

1. معرفی پروژه

این پروژه با هدف بررسی کیفیت، پاکسازی، استانداردسازی و آماده‌سازی داده‌های خام مشتریان برای استفاده در تحلیل داده و گزارش‌گیری انجام شده است.

داده اولیه شامل مشکلات مختلفی در کیفیت و یکپارچگی اطلاعات بود. بنابراین قبل از استفاده از داده در فرآیندهای تحلیلی، ابتدا ساختار و کیفیت داده بررسی و مشکلات موجود شناسایی شد.

فرآیند پاکسازی با استفاده از Microsoft Excel و Power Query انجام شده است.

یکی از اهداف اصلی پروژه، ایجاد یک فرآیند قابل تکرار و قابل کنترل بود؛ به گونه‌ای که در صورت ورود داده‌های جدید، مراحل پاکسازی و کنترل کیفیت بتوانند مجدداً با استفاده از Refresh اجرا شوند.

2. اهداف پروژه

اهداف اصلی پروژه عبارت‌اند از:

- بررسی کیفیت داده‌های خام
- شناسایی مقادیر ناقص و نامعتبر
- شناسایی رکوردهای تکراری
- پاکسازی داده‌های متنی
- استانداردسازی مقادیر
- بررسی سازگاری اطلاعات جغرافیایی
- اصلاح نوع داده ستون‌ها
- ایجاد کنترل‌های کیفیت مستقل
- آماده‌سازی داده نهایی برای تحلیل و گزارش‌گیری
- ایجاد فرآیند قابل تکرار برای داده‌های جدید

3. بررسی اولیه داده خام

در مرحله اول، داده خام از نظر ساختار، نوع داده‌ها، مقادیر Null، مقادیر Zero، مقادیر تکراری و مقادیر غیر استاندارد بررسی شد.

بررسی اولیه نشان داد که برخی ستون‌ها نیاز به پاکسازی و استانداردسازی دارند و استفاده مستقیم از داده خام می‌تواند باعث ایجاد مشکل در دسته‌بندی، فیلتر، محاسبات و گزارش‌گیری شود.

مشکلات اصلی شناسایی شده عبارت‌اند از:

- وجود Null
- وجود Zero در برخی ستون‌های عددی
- وجود CustomerID های تکراری
- وجود فاصله‌های اضافی در داده‌های متنی
- وجود کاراکترهای غیرضروری یا غیرقابل مشاهده
- وجود مقادیر متفاوت برای یک مفهوم یکسان
- وجود مقادیر نامعتبر در ستون Gender
- عدم یکسان بودن نام برخی استان‌ها و شهرها
- احتمال وجود شهرهای نامرتبط با استان
- نیاز به بررسی نوع داده ستون‌ها

4. مدیریت مقادیر Null

مشکل

در برخی ستون‌ها مقدار Null مشاهده شد.

Null لزوماً به معنی خطا نیست و نحوه برخورد با آن باید بر اساس مفهوم و کاربرد هر ستون مشخص شود.

تصمیم

برای هر ستون، مقدار Null به صورت جداگانه بررسی شد.

در مواردی که امکان جایگزینی منطقی وجود داشت، مقدار مناسب جایگزین شد.

در مواردی که اطلاعات کافی برای جایگزینی وجود نداشت، مقدار Null به عنوان داده ناقص در نظر گرفته شد تا در کنترل‌های کیفیت قابل شناسایی باشد.

روش اجرا

بررسی و مدیریت مقادیر Null با استفاده از Power Query انجام شد.

5. بررسی مقادیر Zero

مشکل

در برخی ستون‌های عددی مقدار Zero وجود داشت.

Zero همیشه به معنی مقدار اشتباه نیست و بسته به مفهوم ستون می‌تواند یک مقدار معتبر باشد.

تصمیم

قبل از هرگونه تغییر، مفهوم ستون بررسی شد.

در مواردی که Zero مقدار معتبر محسوب می‌شد، مقدار حفظ شد.

در مواردی که Zero نشان‌دهنده داده نامعتبر یا Missing Data بود، بر اساس ماهیت ستون تصمیم مناسب اتخاذ شد.

روش اجرا

مقادیر Zero در Power Query شناسایی و بررسی شدند.

6. بررسی رکوردهای تکراری

مشکل

یکی از کنترل‌های مهم پروژه، بررسی تکراری بودن CustomerID بود.

از آنجا که CustomerID برای شناسایی مشتری استفاده می‌شود، وجود چند رکورد با یک شناسه می‌تواند باعث ایجاد مشکل در تحلیل و گزارش‌گیری شود.

تصمیم

CustomerID به عنوان معیار اصلی برای کنترل Duplicate در نظر گرفته شد.

رکوردهای تکراری مستقیماً از داده اصلی حذف نشدند؛ ابتدا در یک Query مستقل شناسایی و بررسی شدند.

روش اجرا

یک Query مستقل با نام:

Duplicate Check

ایجاد شد.

این Query با استفاده از قابلیت Reference از داده پاکسازی شده ایجاد شده است.

7. پاکسازی داده‌های متنی

داده‌های متنی می‌توانند به دلیل وجود فاصله‌های اضافی یا کاراکترهای غیرقابل مشاهده باعث ایجاد مقادیر ظاهراً متفاوت شوند.

برای مثال، دو مقدار ممکن است از نظر ظاهری یکسان باشند اما به دلیل وجود فاصله اضافی در سیستم به عنوان دو مقدار متفاوت شناخته شوند.

اقدامات انجام شده

برای پاکسازی داده‌های متنی از دو عملیات اصلی Power Query استفاده شد:

Trim

برای حذف فاصله‌های اضافی در ابتدا و انتهای مقادیر متنی.

Clean

برای حذف کاراکترهای غیرقابل مشاهده و غیرضروری.

این مرحله باعث کاهش اختلاف‌های ناشی از فرمت نامناسب داده‌های متنی شد.

8. استانداردسازی Gender

مشکل

مقادیر ستون Gender به صورت یکسان و استاندارد وارد نشده بودند.

ممکن است یک مفهوم با چند مقدار مختلف در داده نمایش داده شده باشد.

این موضوع می‌تواند باعث ایجاد دسته‌بندی‌های جداگانه و نادرست در گزارش‌گیری شود.

تصمیم

برای ستون Gender یک مجموعه مقدار استاندارد تعریف شد.

مقادیر مختلفی که مفهوم یکسان داشتند به مقدار استاندارد مربوط به خود تبدیل شدند.

روش اجرا

برای استانداردسازی Gender از Mapping و جایگزینی مقادیر در Power Query استفاده شد.

همچنین یک کنترل مستقل برای بررسی مقادیر خارج از استاندارد ایجاد شد.

9. استانداردسازی City و Province

مشکل

نام استان‌ها و شهرها در داده خام لزوماً به صورت استاندارد ثبت نشده بودند.

علاوه بر استانداردسازی نام‌ها، لازم بود سازگاری بین شهر و استان نیز بررسی شود.

تصمیم

برای City و Province از جداول مرجع استفاده شد.

نام‌های مختلف مربوط به یک استان یا شهر به مقدار استاندارد تبدیل شدند.

همچنین ارتباط بین City و Province بررسی شد تا ترکیب‌های احتمالی نامعتبر شناسایی شوند.

روش اجرا

برای تطبیق داده‌ها از قابلیت Merge در Power Query استفاده شد.

جدول مرجع به عنوان منبع استاندارد برای تطبیق اطلاعات مورد استفاده قرار گرفت.

10. بررسی نوع داده‌ها

نوع داده ستون‌ها قبل از استفاده در تحلیل بررسی شد.

نوع داده نادرست می‌تواند باعث ایجاد مشکل در:

- محاسبات
- فیلترها
- مرتب‌سازی
- تبدیل داده
- گزارش‌گیری

شود.

نوع داده هر ستون بر اساس مفهوم آن مشخص شد.

نمونه‌های اصلی:

نوع داده	نوع اطلاعات
Text	اطلاعات متنی
Numeric	اطلاعات عددی
Date / DateTime	اطلاعات تاریخ

اصلاح نوع داده‌ها در Power Query انجام شد.

11. ساختار فرآیند پاکسازی

فرآیند کلی پاکسازی به صورت مرحله‌ای طراحی شد:

Raw Data

|



Data Type Check

|



Text Cleaning

|

└─ Trim

└─ Clean

|



Standardization

|

└─ Gender

└─ Province

└─ City

|



Null / Zero Handling

|



Clean Data

|



Quality Checks

|

└─ Duplicate Check

└─ Null Check

└─ Zero Check

└─ Invalid Value Check

└─ Gender Check

└─ Province Check

└─ City Check

|



Final Data

این ساختار باعث شد عملیات پاکسازی از کنترل‌های کیفیت جدا باشد و هر بخش وظیفه مشخصی داشته باشد.

12. استفاده از Reference در Power Query

یکی از تصمیم‌های مهم پروژه استفاده از قابلیت Reference برای ایجاد Query های کنترلی بود.

به جای اینکه داده برای هر کنترل دوباره کپی شود، Query های کنترل کیفیت از داده پاکسازی شده Reference شدند.

ساختار کلی:

Clean Data

|

└─ Duplicate Check

└─ Null Check

— Zero Check

— Invalid Value Check

— Gender Check

— Province Check

— City Check

مزیت این روش این است که Query های کنترلی مستقیماً به Clean Data وابسته هستند.

بنابراین پس از Refresh، کنترل های کیفیت نیز بر اساس داده جدید مجدداً اجرا می شوند.

13. کنترل های کیفیت داده

پس از انجام مراحل اصلی پاکسازی، داده با استفاده از Query های مستقل بررسی شد.

هدف	کنترل
شناسایی CustomerID های تکراری	Duplicate Check
شناسایی مقادیر Null	Null Check
شناسایی Zero های مشکوک یا نامعتبر	Zero Check
شناسایی مقادیر خارج از استاندارد	Invalid Value Check
بررسی مقادیر نامعتبر Gender	Gender Check
بررسی استان های نامعتبر	Province Check
بررسی شهرهای نامعتبر	City Check

این کنترل ها به عنوان یک لایه بررسی پس از فرآیند پاکسازی در نظر گرفته شدند.

14. حفظ داده خام

یکی از اصول اصلی پروژه، حفظ داده خام و جلوگیری از ویرایش مستقیم آن بود.

داده خام به عنوان منبع اصلی نگهداری شد و عملیات پاکسازی و تبدیل در Power Query انجام گرفت.

این روش مزایای زیر را دارد:

- امکان بازگشت به داده اولیه

- امکان مقایسه **Clean Data** و **Raw Data**
 - جلوگیری از تغییر غیرقابل بازگشت داده اصلی
 - قابل تکرار بودن فرآیند
 - امکان اعمال مجدد مراحل روی داده‌های جدید
-

15. Clean Data

پس از اجرای مراحل پاکسازی، داده در قالب **Clean Data** آماده شد.

Clean Data شامل داده‌هایی است که عملیات اصلی پاکسازی و استانداردسازی روی آنها انجام شده است.

مهم‌ترین عملیات انجام‌شده شامل:

- اصلاح نوع داده
- حذف فاصله‌های اضافی
- حذف کاراکترهای غیرضروری
- استانداردسازی مقادیر
- استانداردسازی **Gender**
- استانداردسازی **Province**
- استانداردسازی **City**
- مدیریت مقادیر قابل اصلاح

است.

16. Final Data

پس از انجام پاکسازی و اجرای کنترل‌های کیفیت، داده نهایی به عنوان **Final Data** آماده استفاده شد.

Final Data برای موارد زیر آماده است:

- **Data Analysis**
- **Reporting**
- **Dashboard Development**
- **Further Data Processing**

هدف از ایجاد **Final Data** این است که داده‌ای که وارد مرحله تحلیل می‌شود، ابتدا از مراحل پاکسازی و کنترل کیفیت عبور کرده باشد.

17. قابلیت Refresh

یکی از اهداف اصلی پروژه، کاهش وابستگی به پاکسازی دستی بود. با ورود داده‌های جدید، فرآیند **Power Query** می‌تواند پس از **Refresh** مجدداً اجرا شود. در این فرآیند:

- داده جدید دریافت می‌شود.
 - مراحل پاکسازی اجرا می‌شوند.
 - استانداردهای اجرا می‌شوند.
 - **Merge**‌های مورد نیاز اجرا می‌شوند.
 - **Query**‌های کنترل کیفیت به روزرسانی می‌شوند.
 - مقادیر نامعتبر قابل شناسایی می‌شوند.
 - **Final Data** به روزرسانی می‌شود.
- بنابراین فرآیند طراحی شده تنها برای یک مجموعه داده خاص نیست و قابلیت استفاده مجدد دارد.
-

18. تصمیم‌های کلیدی پروژه

تصمیم‌های اصلی پروژه عبارت‌اند از:

1. داده خام مستقیماً ویرایش نشود.
2. عملیات پاکسازی در **Power Query** انجام شود.
3. داده‌های متنی با **Trim** و **Clean** پاکسازی شوند.
4. مقادیر **Gender** استاندارد شوند.
5. **Province** و **City** با جداول مرجع تطبیق داده شوند.
6. **CustomerID** برای کنترل **Duplicate** استفاده شود.
7. **Zero** و **Null** بدون بررسی مفهوم ستون جایگزین نشوند.

8. کنترل‌های کیفیت به صورت Query های مستقل ایجاد شوند.

9. Query های کنترلی با استفاده از Reference ساخته شوند.

10. Final Data پس از پاکسازی و کنترل کیفیت مورد استفاده قرار گیرد.

19. نتیجه‌گیری

در این پروژه، داده خام مشتریان از نظر کیفیت و یکپارچگی بررسی و سپس طی چند مرحله پاکسازی و استانداردسازی شد.

مهم‌ترین اقدامات شامل پاکسازی داده‌های متنی، بررسی Null و Zero، کنترل Duplicate، استانداردسازی Gender، استانداردسازی City و Province، بررسی نوع داده‌ها و ایجاد Query های مستقل برای کنترل کیفیت بود.

همچنین با استفاده از Reference در Power Query، کنترل‌های کیفیت به داده پاکسازی شده متصل شدند تا فرآیند پس از Refresh نیز قابل اجرا باشد.

در نتیجه، داده خام به یک مجموعه داده پاکسازی شده، استاندارد شده و قابل کنترل تبدیل شد که برای تحلیل، گزارش‌گیری و توسعه داشبورد آماده است.

هدف پروژه صرفاً اصلاح داده‌های موجود نبود؛ بلکه ایجاد یک فرآیند قابل تکرار، قابل کنترل و قابل استفاده مجدد برای داده‌های جدید نیز مورد توجه قرار گرفت.

Tools Used

- Microsoft Excel
- Power Query

Project Outputs

- Cleaned Dataset
- Data Cleaning Notebook
- Analysis Report